





Clustering Jerárquico

¿Qué es el Clustering Jerárquico?

El Clustering Jerárquico es una técnica de agrupamiento no supervisada que busca construir una jerarquía de grupos (clusters) sin necesidad de definir el número de clusters desde el inicio.




Existen dos enfoques principales:

- 1. Clustering Aglomerativo (Bottom-Up)
- 2. Clustering Divisivo (Top-Down)


Clustering Aglomerativo (Bottom-Up)

- Parte de cada observación como un cluster independiente.
- Iterativamente, fusiona los dos clusters más cercanos.
- Termina cuando todos los puntos forman un solo cluster.
- ✅ Es el método más común.



Clustering Divisivo (Top-Down)

- Comienza con todos los puntos en un solo cluster.
- Los divide recursivamente en subgrupos más pequeños.
- Mucho menos utilizado que el aglomerativo.



Ventajas

- Produce una representación visual (dendrograma) muy interpretativa.
- Adecuado para análisis exploratorio de estructuras jerárquicas.


Limitaciones

- Computacionalmente costoso en datasets grandes.
- Sensible al ruido y a la escala de los datos.

¿Qué son y por qué importan en Clustering Jerárquico? ¿Qué es el “linkage”?

Es la regla que determina la distancia entre clusters cuando se decide cuál par de clusters debe fusionarse en cada paso del clustering jerárquico.

Diferentes métodos producen dendrogramas distintos.




Principales métodos de linkage

1. Single Linkage (mínima distancia)

Calcula la menor distancia entre un punto de un cluster y un punto del otro.


- ◆ Tiende a crear clusters alargados o encadenados.
- ◆ Sensible al ruido y a outliers.



2. Complete Linkage (máxima distancia)

Usa la mayor distancia entre puntos de dos clusters.

- ◆ Produce clusters compactos y esféricos.
- ◆ Menos sensible al ruido que single.




Principales métodos de linkage

1. Average Linkage

Calcula la distancia promedio entre todos los puntos de ambos clusters.


- ◆ Balance entre single y complete.
- ◆ Adecuado cuando los clusters tienen diferentes tamaños.



2. Ward Linkage

Minimiza la varianza total dentro de los clusters.

- ◆ Tiende a formar clusters del mismo tamaño y compactos.
- ◆ Requiere distancias euclídeas.
- ✓ Es el más utilizado en aplicaciones prácticas.



¿Cuál usar?


Método	¿Qué hace?
ward	Recomendado cuando los datos han sido escalados y se busca estructura bien separada.
average o complete	Útiles si se sospecha que los clusters no tienen forma esférica.
single	Sólo en casos donde se buscan estructuras lineales o cadenas.

Visualización con Dendrograma

¿Qué es un dendrograma y cómo se interpreta?


Es una representación gráfica en forma de árbol que muestra cómo los datos se agrupan de forma jerárquica a lo largo del tiempo.

Cada fusión de clusters es representada como una rama del árbol.




¿Qué representa el eje Y?

- El eje vertical indica la distancia (o disimilitud) entre los clusters fusionados.
- Cuanto más alta es la unión, más distintos son los grupos que se están uniendo.




¿Cómo se construye?

- Se parte con todos los puntos individuales.
- Se fusionan los más cercanos según el método de linkage.
- Se continúa hasta que todos los puntos están en un solo cluster.
- El árbol resultante se puede cortar a una cierta altura para definir k clusters.




Corte del dendrograma

- Al trazar una línea horizontal, se define el punto de corte.
- El número de ramas que intersectan esa línea = número de clusters (k).
- La elección del corte puede ser visual o automática (como usando `silhouette_score`).



¿Por qué usar un dendrograma?

- Da una visión clara de la estructura jerárquica de los datos.
- Ayuda a decidir el número de clusters sin especificar k previamente.
- Es útil para detectar outliers o puntos alejados que se unen muy tarde.




Cómo funciona Agglomerative Clustering?

Enfoque Bottom-Up

Agglomerative Clustering es un método jerárquico que comienza desde abajo (bottom-up):

- Cada punto es considerado un cluster individual.
- Se calcula la distancia entre todos los clusters.
- Se fusionan los dos clusters más cercanos.
- El proceso se repite hasta formar el número deseado de clusters (n_clusters).
- Es como construir un árbol desde las hojas hasta la raíz.

Agglomerative Clustering



¿Cómo se decide qué clusters fusionar?

Depende del parámetro linkage:

- **ward (predeterminado):** minimiza la varianza dentro de los clusters.
- **complete:** usa la máxima distancia entre puntos de dos clusters.
- **average:** calcula la distancia promedio entre todos los puntos.
- **single:** usa la distancia mínima (puede generar cadenas de puntos).

Agglomerative Clustering

✓ Ventajas

- ✓ No requiere centroides (como KMeans).
- ✓ Detecta formas complejas si se usa single o average.
- ✓ Fácil de integrar con el flujo de ML moderno.

Diferencias entre AgglomerativeClustering y linkage + fcluster

Dos formas de hacer clustering jerárquico en Python

AgglomerativeClustering

Características:

- ✓ Modelo de clustering jerárquico listo para producción.
- ✓ Implementa fit() y fit_predict().
- ✓ Se integra con Pipeline y con herramientas como GridSearchCV.

Ventajas:

- ✓ Más rápido y práctico para datasets grandes.
- ✓ Compatible con toda la infraestructura de scikit-learn.

Limitaciones:

- ✓ No genera dendrograma (aunque realiza internamente las mismas fusiones).
- ✓ Solo entrega las etiquetas (labels_) finales, no el historial completo de agrupamientos.

Diferencias entre Agglomerative Clustering y linkage + fcluster

Dos formas de hacer clustering jerárquico en Python

scipy → linkage() + fcluster()

Características:

- ✓ Basado en la construcción manual del árbol de fusiones (dendrograma).
- ✓ Ideal para visualización detallada con dendrogram().
- ✓ Necesita corte manual o automático con fcluster() para obtener etiquetas.

Ventajas:

- ✓ Permite graficar dendrogramas fácilmente.
- ✓ Mayor control sobre el proceso de agrupamiento.

Limitaciones:

- ✓ No se integra directamente con Pipeline de scikit-learn.
- ✓ No tiene método fit_predict().

¿Cuál usar?

Criterio	linkage + fcluster	AgglomerativeClustering
Visualización del árbol	✓ Sí	✗ No
Producción / pipelines	✗ No	✓ Sí
Selección automática de k	✓ Sí (manual)	✓ Sí (con loop + score)
Fácil integración con ML	✗ No	✓ Sí

¡Muchas Gracias!

