

CLUSTERING JERÁRQUICO

Rachit Vargas (MBA | Engineer)

rachit.vargas@ulead.ac.cr

(+506) 8474-3543





10.3 Clustering jerárquico

El clustering jerárquico es un método de agrupamiento que organiza los datos en una estructura de árbol (dendrograma) basada en su similitud. Existen dos enfoques principales: **aglomerativo** (bottom-up) y **divisivo** (top-down).





Figura 10.3: Dendrograma obtenido mediante clustering jerárquico aglomerativo.

Definición 10.7 (Clustering jerárquico aglomerativo).


Dado un conjunto de datos $\mathbf{X} = \{x_1, x_2, \dots, x_n\}$ y una medida de disimilitud $d(\cdot, \cdot)$, el algoritmo jerárquico aglomerativo procede como sigue:

1. Inicialización: cada punto $x_i \in \mathbf{X}$ forma un cluster individual $C_i = \{x_i\}$.
2. Iteración: fusionar los dos clusters C_p y C_q que minimizan $d(C_p, C_q)$ según un criterio de enlace (*linkage*).
3. Repetir el paso 2 hasta obtener un único cluster que contiene todos los puntos.

El resultado puede representarse mediante un dendrograma, que muestra las fusiones a diferentes niveles de disimilitud.




Dendrograma
Enlace completo, Distancia eucladiana




Dendrograma

Enlace completo, Distancia eucladiana



Dendrograma

Enlace completo, Distancia eucladiana



Algoritmo del clustering jerárquico aglomerativo

Sea $I = \{1, \dots, n\}$ el conjunto de objetos. El algoritmo construye una jerarquía binaria (dendrograma) mediante fusiones sucesivas de clusters hasta obtener un único cluster que contiene todos los elementos.

1. **Inicialización.** El procedimiento empieza con las clases que se reducen a un solo elemento, es decir con la partición

$$P_0 = \{\{1\}, \{2\}, \dots, \{n\}\}, \quad h = 0.$$

2. **Formación de nuevos nodos.** Se fusionan los dos nodos de P_h más cercanos en el sentido de la agregación δ . Es decir, si x y y son estos dos nodos entonces

$$\delta(x, y) = \min\{\delta(l, k) \mid l, k \in P_h, l \neq k\}.$$

3. **Actualización de P_h .** Sea $h \leftarrow h + 1$ y $P_h \leftarrow [P_h \cup \{x \cup y\}] - \{x, y\}$.

4. **Test (criterio de parada).** Si $h < n - 2$ regresar al paso 2. En otro caso, hacer la última fusión y terminar.
-

Notación.


- n número total de objetos.
 - P_h partición del conjunto en el paso h .
 - $|P_h| = n - h$ número de clusters en el paso h .
 - $\delta(A, B)$ distancia entre dos clusters A y B según el criterio de enlace (*linkage*).
 - h número de fusiones realizadas (altura del dendrograma).
-

Ejemplo completo: cálculo de distancias y construcción del dendrograma (clustering jerárquico aglomerativo)

1 Dataset

Consideremos los siguientes 5 puntos en $\mathbb{R}^2$.

Punto	x_1	x_2
A	1	2
B	2	1
C	4	1
D	5	4
E	7	3



2 Matriz de distancias inicial

Usamos la distancia euclídea: $d(i, j) = \sqrt{(x_{1i} - x_{1j})^2 + (x_{2i} - x_{2j})^2}$.

	A	B	C	D	E
A	0	1.41	3.16	5.00	6.32
B	1.41	0	2.00	4.24	5.39
C	3.16	2.00	0	3.16	3.61
D	5.00	4.24	3.16	0	2.24
E	6.32	5.39	3.61	2.24	0

Cálculos (ejemplos)

- $d(A, B) = \sqrt{(1-2)^2 + (2-1)^2} = 1.41$
- $d(A, C) = \sqrt{(1-4)^2 + (2-1)^2} = 3.16$
- $d(D, E) = \sqrt{(5-7)^2 + (4-3)^2} = 2.24$

3 Paso 1: fusionar los más cercanos

Mínima distancia: $d(A, B) = 1.41$

Se fusionan A y B $\rightarrow (AB)$

	AB	C	D	E
AB	0	2.55	4.61	5.85
C	2.55	0	3.16	3.61
D	4.61	3.16	0	2.24
E	5.85	3.61	2.24	0

$$\begin{aligned} \text{Distancia } (AB, C) &= \frac{1}{2} (d(A, C) + d(B, C)) \\ &= \frac{1}{2} (3.16 + 2.00) = 2.55 \\ &\text{(Promedio de enlace simple/promedio)} \end{aligned}$$

4 Paso 2: fusionar los más cercanos

Mínima distancia: $d(D, E) = 2.24$

Se fusionan D y E $\rightarrow (DE)$

	AB	C	DE
AB	0	2.55	5.05
C	2.55	0	3.39
DE	5.05	3.39	0

$$\begin{aligned} \text{Distancia } (AB, DE) &= \frac{1}{4} \sum_{i \in \{A, B\}} \sum_{j \in \{D, E\}} d(i, j) \\ &= \frac{1}{4} (5.00 + 6.32 + 4.24 + 5.39) = 5.05 \\ &\text{(Promedio entre todos los pares)} \end{aligned}$$

5 Paso 3: fusionar los más cercanos

Mínima distancia: $d(AB, C) = 2.55$

Se fusionan (AB) y C $\rightarrow (ABC)$


	ABC	DE
ABC	0	4.44
DE	4.44	0

$$\begin{aligned} \text{Distancia } (ABC, DE) &= \frac{1}{6} \sum_{i \in \{A, B, C\}} \sum_{j \in \{D, E\}} d(i, j) \\ &= \frac{1}{6} (5.00 + 6.32 + 4.24 + 5.39 + 3.16 + 3.61) \\ &= 4.44 \end{aligned}$$

6 Paso 4: última fusión

Única distancia: $d(ABC, DE) = 4.44$

Se fusionan (ABC) y (DE)




Se obtiene un único cluster que contiene todos los puntos.

7 Dendrograma final

El dendrograma muestra las fusiones sucesivas a diferentes niveles de disimilitud (altura de fusión).

- A y B se fusionan a altura 1.41
- D y E se fusionan a altura 2.24
- (AB) y C se fusionan a altura 2.55
- (ABC) y (DE) se fusionan a altura 4.44



Resumen de distancias usadas

- $d(A, B) = 1.41$
- $d(D, E) = 2.24$
- $d(AB, C) = 2.55$
- $d(ABC, DE) = 4.44$

CÓMO CALCULAR UNA MATRIZ DE DISTANCIA

Ejemplo con una tabla de notas escolares

1 Datos

Tenemos n estudiantes y p asignaturas.
Cada estudiante es un punto en $\mathbb{R}^p$.

	Matemáticas	Ciencias	Español	Historia	EdFísica
Lucía	7.0	6.5	9.2	8.6	8.0
Pedro	7.5	9.4	7.3	7.0	7.0
Inés	7.6	9.2	8.0	8.0	7.5
Luis	5.0	6.5	6.5	7.0	9.0
Andrés	6.0	6.0	7.8	8.9	7.3
Ana	7.8	9.6	7.7	8.0	6.5
Carlos	6.3	6.4	8.2	9.0	7.2
José	7.9	9.7	7.5	8.0	6.0
Sonia	6.0	6.0	6.5	5.5	8.7
María	6.8	7.2	8.7	9.0	7.0

2 Elección de la distancia

Usamos la distancia euclídea entre estudiantes i y j :

$$d_{ij} = \sqrt{\sum_{k=1}^p (x_{ik} - x_{jk})^2}$$

donde:

- x_{ik} = nota del estudiante i en la asignatura k
- p = número de asignaturas (aquí $p = 5$)

3 Cálculo de una distancia (ejemplo)

Calculemos la distancia entre Lucía y Pedro.

Lucía = (7.0, 6.5, 9.2, 8.6, 8.0)

Pedro = (7.5, 9.4, 7.3, 7.0, 7.0)

$$\begin{aligned}d_{\text{Lucía, Pedro}} &= \sqrt{(7.0 - 7.5)^2 + (6.5 - 9.4)^2 + (9.2 - 7.3)^2 + (8.6 - 7.0)^2 + (8.0 - 7.0)^2} \\&= \sqrt{(-0.5)^2 + (-2.9)^2 + (1.9)^2 + (1.6)^2 + (1.0)^2} \\&= \sqrt{0.25 + 8.41 + 3.61 + 2.56 + 1.00} \\&= \sqrt{15.83} \approx 3.98\end{aligned}$$

4 Cálculo de todas las distancias

Se calcula la distancia euclídea entre cada par de estudiantes.

La matriz de distancia es simétrica: $d_{ij} = d_{ji}$ y $d_{ii} = 0$.

Par de estudiantes	Distancia
Lucía – Pedro	3.98
Lucía – Inés	2.02
Lucía – Luis	3.34
⋮	⋮
María – José	2.04



Nota:

Solo necesitamos calcular una vez cada par (i, j) con $i < j$.
El resto se obtiene por simetría.



5 Matriz de distancia (euclídea)

Cada entrada (i, j) es la distancia entre el estudiante i y el estudiante j .

	Lucía	Pedro	Inés	Luis	Andrés	Ana	Carlos	José	Sonia	María
Lucía	—									
Pedro	3.98	—								
Inés	2.02	2.48	—							
Luis	3.34	4.61	4.50	—						
Andrés	1.74	3.61	2.62	2.97	—					
Ana	2.62	1.01	1.90	4.64	1.88	—				
Carlos	2.58	3.35	1.31	4.08	2.00	2.03	—			
José	2.77	0.75	1.91	4.74	2.30	0.90	2.13	—		
Sonia	3.20	4.75	4.08	1.76	2.84	4.79	4.42	4.87	—	
María	2.46	2.27	0.73	3.49	1.49	1.83	1.31	2.04	3.44	—


Criterios de agregación (enlace) en clustering jerárquico aglomerativo

En cada paso del algoritmo aglomerativo se deben fusionar dos clusters A y B según un criterio de enlace (*linkage*), que determina la distancia $d(A, B)$ entre clusters.


1. Salto mínimo (single linkage)

La distancia entre dos clusters es la menor distancia entre cualquier par de puntos, uno en cada cluster.

$$d_{\min}(A, B) = \min_{x \in A, y \in B} d(x, y)$$



Se considera el par de puntos más cercano entre los clusters.




Tiende a formar clusters alargados o cadenas, pues une grupos por un único punto cercano (efecto de encadenamiento).


2. Salto máximo (complete linkage)

La distancia entre dos clusters es la mayor distancia entre cualquier par de puntos, uno en cada cluster.

$$d_{\max}(A, B) = \max_{x \in A, y \in B} d(x, y)$$



Se considera el par de puntos más lejano entre los clusters.




Tiende a formar clusters compactos y de tamaño similar, pues exige que todos los puntos estén relativamente cerca.


3. Promedio (average linkage)

La distancia entre dos clusters es el promedio de las distancias entre todos los pares de puntos, uno en cada cluster.

$$d_{\text{prom}}(A, B) = \frac{1}{|A||B|} \sum_{x \in A} \sum_{y \in B} d(x, y)$$



Se considera el promedio de todas las distancias entre puntos de ambos clusters.




Compromiso entre los anteriores: evita cadenas largas pero permite clusters de formas y tamaños moderadamente variables.

4. Ward (mínima varianza)


Se fusionan los clusters que producen el menor aumento en la suma total de cuadrados intra-cluster (varianza dentro de los clusters).

$$d_{\text{Ward}}(A, B) = \Delta(A, B) = \frac{n_A n_B}{n_A + n_B} \|\bar{x}_A - \bar{x}_B\|^2$$

donde n_A, n_B son los tamaños de los clusters y $\bar{x}_A, \bar{x}_B$ sus centroides.



Se consideran los centroides y tamaños de los clusters; se busca mínima varianza interna.




Tiende a formar clusters esféricos y de tamaño similar; es el criterio más usado en la práctica.

La elección del criterio de enlace influye fuertemente en la forma y el número de clusters obtenidos. No existe un criterio universalmente mejor; depende de la estructura de los datos y del objetivo del análisis.

Clustering jerárquico aglomerativo: métodos de enlace (linkage)

Conjunto de datos (4 puntos en $\mathbb{R}^2$)

Punto	x_1	x_2
X1	0	0
X2	5	0
X3	3	0
X4	2	1



Matriz de distancias inicial (euclídea)
(triangular inferior)

	X1	X2	X3	X4
X1	—			
X2	5	—		
X3	3	2	—	
X4	2	4.24	1	—

En cada paso se fusionan los dos clusters con menor distancia según el criterio de enlace.

Leyenda:

- No aplica (diagonal)
- Distancia entre clusters

Altura = distancia a la que ocurre la fusión (se refleja en el dendrograma).

1 Salto mínimo (single linkage)

Distancia entre dos clusters = mínima distancia entre cualquier par de puntos, uno de cada cluster.

$$d(A, B) = \min_{x \in A, y \in B} d(x, y)$$

Paso 1: min = 1 entre (X3, X4)
Se fusionan $C_1 = \{X3, X4\}$ (altura = 1)

	X1	X2	X3	X4
X2	5	—		
X3	3	2	—	
X4	2	4.24	1	—

Paso 2: distancias a $C_1 = \{X3, X4\}$
 $d(C_1, X_i) = \min(d(X3, X_i), d(X4, X_i))$

	X1	X2	C_1
X2	5	—	
C_1	2	2	—


Paso 3: min = 2 entre (X1, C_1)
Se fusionan $C_2 = \{X1, X3, X4\}$ (altura = 2)

	X1	X2	C_1
X2	5	—	
C_1	2	2	—

Paso 4: última fusión
Se fusionan (C_2 , X2) a altura = 2

	X2	C_2
C_2	2	—

Dendrograma (salto mínimo)



2 Salto máximo (complete linkage)

Distancia entre dos clusters = máxima distancia entre cualquier par de puntos, uno de cada cluster.

$$d(A, B) = \max_{x \in A, y \in B} d(x, y)$$

Paso 1: min = 1 entre (X3, X4)
Se fusionan $C_1 = \{X3, X4\}$ (altura = 1)

	X1	X2	X3	X4
X2	5	—		
X3	3	2	—	
X4	2	4.24	1	—

Paso 2: distancias a $C_1 = \{X3, X4\}$
 $d(C_1, X_i) = \max(d(X3, X_i), d(X4, X_i))$

	X1	X2	C_1
X2	5	—	
C_1	3	4.24	—


Paso 3: min = 3 entre (X1, C_1)
Se fusionan $C_2 = \{X1, X3, X4\}$ (altura = 3)

	X1	X2	C_1
X2	5	—	
C_1	3	4.24	—

Paso 4: última fusión
Se fusionan (C_2 , X2) a altura = 5

	X2	C_2
C_2	5	—

Dendrograma (salto máximo)



3 Promedio (average linkage)

Distancia entre dos clusters = promedio de las distancias entre todos los pares de puntos.

$$d(A, B) = \frac{1}{|A||B|} \sum_{x \in A} \sum_{y \in B} d(x, y)$$

Paso 1: min = 1 entre (X3, X4)
Se fusionan $C_1 = \{X3, X4\}$ (altura = 1)

	X1	X2	X3	X4
X2	5	—		
X3	3	2	—	
X4	2	4.24	1	—

Paso 2: distancias a $C_1 = \{X3, X4\}$
 $d(C_1, X_i) = \text{promedio de distancias}$

	X1	X2	C_1
X2	5	—	
C_1	2.5	3.12	—

$$d(C_1, X1) = (d_{31} + d_{41})/2 = (3 + 2)/2 = 2.5$$

$$d(C_1, X2) = (d_{32} + d_{42})/2 = (2 + 4.24)/2 = 3.12$$


Paso 3: min = 2.5 entre (X1, C_1)
Se fusionan $C_2 = \{X1, X3, X4\}$ (altura = 2.5)

	X1	X2	C_1
X2	5	—	
C_1	2.5	3.12	—

Paso 4: última fusión
Se fusionan (C_2 , X2) a altura = 3.12

	X2	C_2
C_2	3.12	—

Dendrograma (promedio)



4 Ward (mínima varianza)

Se fusionan los clusters que producen el menor aumento en la suma de cuadrados intra-cluster.

$$d_{\text{Ward}}(A, B) = \frac{n_A n_B}{n_A + n_B} \|\bar{x}_A - \bar{x}_B\|^2$$

donde n_A, n_B son tamaños y $\bar{x}_A, \bar{x}_B$ centroides.

Paso 1: min = 1 entre (X3, X4)
Se fusionan $C_1 = \{X3, X4\}$ (altura = 1)

	X1	X2	X3	X4
X2	5	—		
X3	3	2	—	
X4	2	4.24	1	—

Paso 2: distancias a $C_1 = \{X3, X4\}$
Cálculo con fórmula de Ward.

	X1	X2	C_1
X2	5	—	
C_1	2.33	3.33	—

$$d_{\text{Ward}}(C_1, X1) = 2.33, \quad d_{\text{Ward}}(C_1, X2) = 3.33$$


Paso 3: min = 2.33 entre (X1, C_1)
Se fusionan $C_2 = \{X1, X3, X4\}$ (altura = 2.33)

	X1	X2	C_1
X2	5	—	
C_1	2.33	3.33	—

Paso 4: última fusión
Se fusionan (C_2 , X2) a altura = 4.80


	X2	C_2
C_2	4.80	—

Dendrograma (Ward)



Gráficos para la interpretación de clusters

Una vez obtenido el agrupamiento (por ejemplo, mediante clustering jerárquico), los siguientes gráficos ayudan a comprender y caracterizar los clusters.



CLUSTERING JERÁRQUICO

Rachit Vargas (MBA | Engineer)

rachit.vargas@ulead.ac.cr

(+506) 8474-3543