

REDUCCIÓN DE DIMENSIONALIDAD

Rachit Vargas (MBA | Engineer)

rachit.vargas@ulead.ac.cr

(+506) 8474-3543

$$\mathbf{A} = \begin{pmatrix} a_{11} & a_{12} & a_{13} & \dots & a_{1n} \\ a_{21} & a_{22} & a_{23} & \dots & a_{2n} \\ a_{31} & a_{32} & a_{33} & \dots & a_{3n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & a_{m3} & \dots & a_{mn} \end{pmatrix}$$

1. El problema de la alta dimensionalidad

1.1. Ocurre cuando un conjunto de datos tiene un número muy grande de variables (dimensiones)

1.2. Ejemplo de esto son conjuntos de datos como:

- a. Imágenes con miles de píxeles
- b. Datasets con diferentes mediciones
- c. Sensores con cientos de dimensiones


1.3. A mayor dimensión, los puntos de datos están cada vez mas lejos entre si en un espacio dimensional

1.4. Los problemas más importantes de la alta dimensionalidad son:

- a. Complejidad computacional
- b. Riesgo de sobre ajuste en modelaje supervisado
- c. Dificultad al interpretar y visualizar datos en altas dimensiones


Con muchas variables, los modelos pueden aprender el ruido en lugar del patrón real.

Modelo adecuado



Generaliza bien

Modelo sobreajustado




Aprende el ruido

A mayor dimensión, los puntos están tan alejados entre sí que el espacio se vuelve “vacío”.


2D

Espacio lleno




10D

Empieza a dispersarse



100D

Muy disperso (casi vacío)



1.2. El problema

- Se trata de sintetizar los datos contenidos en una tabla de datos X en un conjunto más pequeño de nuevas variables $C^1, C^2, \dots$ llamadas componentes principales, manteniendo la información esencial de X .
- Así, en la etapa 1 del algoritmo se encuentra una **variable sintética** C^1 , la primera componente principal, la cual es combinación lineal de las variables originales X^j , es decir:


$$C^1 = a_{11}X^1 + \dots + a_{1j}X^j + \dots + a_{1m}X^m,$$

donde X^j es la columna j de X . Esto significa que el valor de C^1 para el individuo i -ésimo está dado por:


$$C_i^1 = a_{11}x_{i1} + \dots + a_{1j}x_{ij} + \dots + a_{1m}x_{im},$$

- Generalmente esta primer componente principal, C^1 , no es suficiente para condensar la información contenida en X , por lo que se construye una segunda componente principal C^2 , luego una tercera C^3 y así sucesivamente.
- En general en la etapa k , se construye la componente principal k -ésima dada por:


$$C^k = a_{k1}X^1 + \cdots + a_{kj}X^j + \cdots + a_{km}X^m.$$



Elliptical cloud of centered data
with covariance Σ .



Direction of maximum variance.
Variance = λ_1 .



Orthogonal to $\mathbf{v}_1$.
Maximum remaining variance.
Variance = λ_2 .

1. PCA finds the direction of maximum variance (linear projection).

For any unit vector $\mathbf{w} \in \mathbb{R}^2$ with $\|\mathbf{w}\| = 1$, the projection of a centered random vector $\mathbf{X}$ onto $\mathbf{w}$ is $Y = \mathbf{w}^\top \mathbf{X}$.

The variance of this projection is

$$\text{Var}(Y) = \text{Var}(\mathbf{w}^\top \mathbf{X}) = \mathbf{w}^\top \Sigma \mathbf{w}.$$

PCA chooses $\mathbf{v}_1$ to maximize this variance:

$$\max_{\|\mathbf{w}\|=1} \mathbf{w}^\top \Sigma \mathbf{w}.$$

Solution: $\mathbf{v}_1$ is the unit eigenvector of Σ associated with the largest eigenvalue λ_1 . The variance explained is λ_1 .

2. Remaining variance in orthogonal direction.

To find the next direction, restrict to vectors orthogonal to $\mathbf{v}_1$: $\mathbf{w}^\top \mathbf{v}_1 = 0$, $\|\mathbf{w}\| = 1$.

Maximize $\mathbf{w}^\top \Sigma \mathbf{w}$ subject to this constraint. The solution is $\mathbf{v}_2$, the unit eigenvector of Σ associated with the second largest eigenvalue λ_2 .

This direction is orthogonal to $\mathbf{v}_1$ and captures the maximum remaining variance.


3. Orthogonality of principal components.

Since Σ is symmetric positive semidefinite, eigenvectors corresponding to distinct eigenvalues are orthogonal.


$$\mathbf{v}_i^\top \mathbf{v}_j = 0 \quad \text{for } i \neq j.$$

Thus, the principal components form an orthonormal basis of $\mathbb{R}^2$ (and $\mathbb{R}^p$ in general).


Datos originales en 3D




Proyección en 2 componentes principales (PC1 vs PC2)



Proyección en 1 componente principal (solo PC1)




← Mayor variabilidad explicada por PC1 →




2. Algoritmo PCA

1. Estandarizar (centrar)



Restar la media a cada variable.

2. Covarianza




Calcular matriz S ($p \times p$).

En este punto nos interesa saber que variables están correlacionadas

Y en que dirección hay más variación conjunta

3. Autovalores y autovectores



Obtener λ_j y $\mathbf{v}_j$.
Ordenar por λ_j .

Los autovalores y autovectores nos indican las direcciones principales y el autovalor cuanta varianza hay en cada dirección


4. Elegir k componentes

$\mathbf{v}_1 \quad \mathbf{v}_2 \quad \dots \quad \mathbf{v}_k$

Seleccionar las k direcciones más importantes.

En este punto, ordenamos las k direcciones que tienen mayor varianza (información)

5. Proyectar



Obtener $Z = \tilde{X}V_k$ (datos en k -dim).

Representamos los datos en menos dimensiones

Ejemplo. Considere el siguiente conjunto de datos:

Edad (años)	Ingreso (\$)
20	20 000
30	50 000
40	80 000

(a) Compare las varianzas de ambas variables y explique cuál domina.

$$Var(X) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$
$$Var(aX) = a^2 Var(X)$$

Para *Edad*: $\bar{x}_E = \frac{20+30+40}{3} = 30$

$Var(Edad) = \frac{1}{3} [(20 - 30)^2 + (30 - 30)^2 + (40 - 30)^2] = \frac{200}{3} \approx 66.67$

Para *Ingreso*: $\bar{x}_I = \frac{20000+50000+80000}{3} = 50000$

$Var(Ingreso) = \frac{1}{3} [(20000 - 50000)^2 + (50000 - 50000)^2 + (80000 - 50000)^2]$
$$= \frac{1}{3} (900000000 + 0 + 900000000) = 600000000$$

Conclusión: $Var(Edad) \ll Var(Ingreso) \Rightarrow$ *Ingreso* domina la varianza (mayor escala).

(b) Explique qué ocurre al aplicar PCA sin estandarizar.

PCA estará dominado por la variable *Ingreso*.

(c) Estandarice las variables usando $X' = \frac{X - \mu}{\sigma}$.

$$X' = \frac{X - \mu}{\sigma}$$

Edad	Ingreso	Edad'	Ingreso'
20	20 000	-1	-1
30	50 000	0	0
40	80 000	1	1

(d) Calcule la varianza de las variables estandarizadas.

Las variables estandarizadas tienen media 0 y desviación estándar 1. Por tanto,

$Var(Edad') = 1$ y $Var(Ingreso') = 1$.

(e) Concluya el efecto de la estandarización en PCA.

PCA deja de estar sesgado por la escala de las variables.

Algoritmo

Entrada: Las tabla de datos $X \in M_{n \times m}$.

Salida: La matriz de componentes principales $C \in M_{n \times m}$.

Paso 1: Centrar y reducir la tabla de datos X .

Paso 2: Calcular la matriz de correlaciones $R \in M_{m \times m}$. R se puede calcular: $R = \frac{1}{n}X^T X$, o bien a pie calculando todas las correlaciones.

Paso 3: Calcular los vectores y valores propios de la matriz $R \in M_{m \times m}$.

Paso 4: Ordenar de mayor a menor estos valores propios.

Paso 5: Si denotamos por $\lambda_1, \lambda_2, \dots, \lambda_m$ estos valores propios ordenados y por $v_1, v_2, \dots, v_m$ los respectivos vectores propios, entonces se construye la matriz $V \in M_{m \times m}$ de la siguiente forma:

$$V = [v_1 \mid v_2 \mid \dots \mid v_m]$$

Es decir, la matriz V tiene como columnas los vectores $v_1, v_2, \dots, v_m$.

Paso 6: Calcule la matriz de componentes principales $C \in M_{n \times m}$:

$$C = X \cdot V$$

Paso 7: Calcule la matriz de calidades de los individuos (cosenos cuadrados) $Q \in M_{n \times m}$, como sigue:

$$Q_{ir} = \frac{(C_{i,r})^2}{\sum_{j=1}^m (X_{ij})^2} \quad \text{para } i = 1, 2, \dots, n; \quad r = 1, 2, \dots, m.$$

Paso 8: Calcule la matriz de coordenadas de las variables $T \in M_{m \times m}$, como sigue:

$$T = \begin{pmatrix} \sqrt{\lambda_1} v_{1,1} & \cdots & \sqrt{\lambda_r} v_{1,r} & \cdots & \sqrt{\lambda_m} v_{1,m} \\ \vdots & \vdots & \cdots & \vdots & \vdots \\ \sqrt{\lambda_1} v_{j,1} & \cdots & \sqrt{\lambda_r} v_{j,r} & \cdots & \sqrt{\lambda_m} v_{j,m} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \sqrt{\lambda_1} v_{m,1} & \cdots & \sqrt{\lambda_r} v_{m,r} & \cdots & \sqrt{\lambda_m} v_{m,m} \end{pmatrix}$$

Paso 9: Calcule la matriz de calidades de las variables (cosenos cuadrados) $S \in M_{m \times m}$, como sigue:

$$S = \begin{pmatrix} \lambda_1(v_{1,1})^2 & \cdots & \lambda_r(v_{1,r})^2 & \cdots & \lambda_m(v_{1,m})^2 \\ \lambda_1(v_{j,1})^2 & \cdots & \lambda_r(v_{j,r})^2 & \cdots & \lambda_m(v_{j,m})^2 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \lambda_1(v_{m,1})^2 & \cdots & \lambda_r(v_{m,r})^2 & \cdots & \lambda_m(v_{m,m})^2 \end{pmatrix}$$

Paso 10: Calcule el vector de inercias de los ejes $I \in M_{1 \times m}$, como sigue:

$$I = (100 \cdot \frac{\lambda_1}{m}, 100 \cdot \frac{\lambda_2}{m}, \dots, 100 \cdot \frac{\lambda_m}{m})$$

1.3. Eigenvectores y Eigenvalores

- Son vectores v que al aplicar la matriz de covarianza Σ solo cambian de escala, no de dirección ($\Sigma v = \lambda v$). los eigenvectores forman un sistema de coordenadas nuevo, ortogonal (independiente), que elimina correlaciones entre variables. Al proyectar los datos en estos ejes, cada componente captura información única, sin redundancia.
- Por otro lado, cada eigenvalor λ mide cuánta varianza existe a lo largo de su eigenvector asociado. En PCA, esto cuantifica cuánta "información" contiene cada componente principal. Al ordenar los eigenvalores de mayor a menor, se identifican las direcciones más importantes. PCA conserva los eigenvectores con mayores eigenvalores porque concentran la mayor parte de la varianza total, permitiendo reducir dimensiones con mínima pérdida de información.

2. Algoritmo PCA

2.1. El algoritmo de PCA arrojará elementos que deberán interpretarse:

- a. Varianza explicada por componente principal
- b. Plano principal
- c. Círculo de correlación
- d. Biplot – Gráfico de superposición

2.2. Otros elementos a analizar:

- a. Contribución de cada variable proyectado por el PCA
- b. Coseno cuadrado de cada individuo proyectado por el PCA

Dataset: decathlon2

Datos de atletas en competencias de decatlón

1. DESCRIPCIÓN GENERAL

El dataset **decathlon2** contiene información sobre el rendimiento de atletas en competencias de decatlón.

Nº de atletas	41
Competiciones	Olímpicos y Decastar
Pruebas por atleta	10 pruebas deportivas
Otras variables	Puntos totales y rango final

Cada fila representa un atleta y cada columna una prueba o resultado.


2. VARIABLES DEL DATASET

Pruebas de rendimiento (10)			Resultados agregados (2)	Información adicional (1)
1	100m	Carrera de 100 metros	Points Puntos totales obtenidos en el decatlón	Competition Tipo de competencia: 'Olympic' o 'Decastar'
2	Long.jump	Salto largo		
3	Shot.put	Lanzamiento de bala		
4	High.jump	Salto alto		
5	400m	Carrera de 400 metros	Rank Posición final del atleta	En total: 13 variables (10 pruebas + 2 resultados + 1 información adicional)
6	110m.hurdle	Carrera de 110 metros con vallas		
7	Discus	Lanzamiento de disco		
8	Pole.vault	Salto con pértiga		
9	Javeline	Lanzamiento de jabalina		
10	1500m	Carrera de 1500 metros		


3. VISTA DE LOS DATOS (primeras filas)

	100m	Long.jump	Shot.put	High.jump	...	Javeline	1500m	Points	Rank	Competition
B.DENOIX	10.88	7.23	15.66	1.98	...	78.56	255.7	7751	1	Decastar
D.SIEGFRIED	10.76	7.15	15.64	1.95	...	77.92	245.7	7576	2	Decastar
A.DEJUIGNE	10.91	7.38	14.07	1.98	...	70.30	249.5	7340	3	Decastar
D.VAUCHEL	11.14	6.81	15.50	1.92	...	64.42	259.7	7116	4	Decastar
G.MION	10.98	6.33	13.15	1.86	...	69.04	249.7	6732	5	Decastar
...	...	...	...	...	...	...	...	...	...	...
J.ZELEZNY	11.48	7.91	16.11	2.15	...	87.08	264.1	8816	1	Olympic


4. ¿PARA QUÉ SE USA ESTE DATASET?




Scree plot




Individuals - PCA



Variables - PCA



PCA - Biplot



2. COSENO CUADRADO ($\cos^2$)

DEFINICIÓN

El $\cos^2$ mide la calidad de representación de una variable en un eje principal.

Para la variable j en el componente k :

$$\cos^2_{jk} = \frac{\text{cor}(X_j, Z_k)^2}{\sum_{l=1} \text{cor}(X_j, Z_l)^2}$$

En PCA con datos estandarizados:

$$\cos^2_{jk} = \text{cor}(X_j, Z_k)^2$$

INTERPRETACIÓN

- $\cos^2_{jk} \approx 1$: la variable X_j está bien representada en el componente k .
- $\cos^2_{jk} \approx 0$: la variable X_j está mal representada en el componente k .

INTERPRETACIÓN GEOMÉTRICA

El $\cos^2$ es el cuadrado del coseno del ángulo entre la variable X_j y el componente Z_k .

$$\cos^2_{jk} = \cos^2(\theta_{jk})$$

PROPIEDAD

Para cada variable j , $\sum_{k=1}^p \cos^2_{jk} = 1$.

3. CONTRIBUCIÓN DE UNA VARIABLE

DEFINICIÓN

La contribución de la variable j al componente k mide cuánto aporta esa variable a la construcción del eje k .

$$\text{ctr}_{jk} = \frac{\text{cor}(X_j, Z_k)^2}{\lambda_k}$$

donde λ_k es el valor propio del componente k .

PROPIEDAD CLAVE

Para cada componente k , $\sum_{j=1}^p \text{ctr}_{jk} = 1$.

Es decir, las contribuciones de todas las variables al componente k suman 1 (o 100%).

INTERPRETACIÓN

- ctr_{jk} grande $\Rightarrow$ la variable j contribuye mucho a formar el eje k .
- ctr_{jk} pequeña $\Rightarrow$ la variable j contribuye poco al eje k .

RELACIÓN ENTRE $\cos^2$ Y CONTRIBUCIÓN

Como $\cos^2_{jk} = \text{cor}(X_j, Z_k)^2$, entonces

$$\text{ctr}_{jk} = \frac{\cos^2_{jk}}{\lambda_k}$$

La contribución ajusta el $\cos^2$ por la importancia del componente k (su valor propio λ_k).

4. EJEMPLO NUMÉRICO

Supongamos un PCA con $p = 4$ variables y dos componentes principales.

Valores propios: $\lambda_1 = 2.50$, $\lambda_2 = 1.30$.

Cos² de las variables

Variable	$\cos^2_{j1}$	$\cos^2_{j2}$	$\cos^2_{j1} + \cos^2_{j2}$
X_1	0.70	0.20	0.90
X_2	0.60	0.10	0.70
X_3	0.15	0.60	0.75
X_4	0.05	0.75	0.80

$\Rightarrow$

Contribuciones de las variables

Variable	$\text{ctr}_{j1} = \frac{\cos^2_{j1}}{2.50}$	$\text{ctr}_{j2} = \frac{\cos^2_{j2}}{1.30}$
X_1	0.28	0.15
X_2	0.24	0.08
X_3	0.06	0.46
X_4	0.02	0.58

Verificación:

$$\sum_{j=1}^4 \text{ctr}_{j1} = 1.00$$

$$\sum_{j=1}^4 \text{ctr}_{j2} = 1.00$$

Ventajas	Desventajas
● Reducción de dimensionalidad: PCA permite representar los datos en un espacio de menor dimensión conservando la mayor variabilidad posible.	● Interpretabilidad limitada: las componentes principales son combinaciones lineales de las variables originales, lo que puede dificultar su interpretación física o práctica.
● Eliminación de multicolinealidad: al transformar las variables originales en componentes no correlacionadas, PCA elimina la multicolinealidad perfecta.	● Sensible a la escala: PCA depende de la escala de las variables; por lo tanto, es necesario estandarizarlas para evitar que variables con mayor magnitud dominen el análisis.
● Compresión de datos: facilita el almacenamiento, la visualización y el procesamiento al trabajar con menos variables.	● Supone relaciones lineales: PCA solo captura estructuras lineales en los datos; no es adecuado para relaciones no lineales.
● Minimiza la pérdida de información: conserva la máxima varianza posible con el menor número de componentes.	● Sensible a valores atípicos: los outliers pueden influir significativamente en las componentes principales y distorsionar los resultados.
● Útil en múltiples aplicaciones: es ampliamente utilizado en exploración de datos, reducción de ruido, reconocimiento de patrones y preprocesamiento para otros modelos.	● No considera la variable respuesta: PCA es un método no supervisado, por lo que no toma en cuenta información sobre la variable objetivo (puede no ser óptimo para predicción).

Uso	Description
1. Reducción de dimensionalidad	Reduce el número de variables originales conservando la mayor parte de la variabilidad de los datos. Se conservan los primeros k componentes principales $\mathbf{v}_1, \dots, \mathbf{v}_k$ que explican la mayor proporción de la varianza total $\sum_{i=1}^k \lambda_i / \sum_{i=1}^p \lambda_i$.
2. Visualización de datos	Permite visualizar datos de alta dimensión en 2D o 3D utilizando los primeros dos o tres componentes principales, que capturan las direcciones de mayor variación.
3. Reducción de ruido	Al proyectar los datos sobre los componentes principales dominantes y descartar los asociados a valores propios pequeños, PCA filtra el ruido y preserva la estructura esencial de los datos.
4. Extracción de características	Genera nuevas características (componentes principales) no correlacionadas, que son combinaciones lineales de las variables originales y capturan los patrones más importantes de los datos.
5. Manejo de multicolinealidad	Transforma variables correlacionadas en un conjunto ortogonal de componentes principales, mitigando problemas de multicolinealidad en regresiones y otros análisis estadísticos.
6. Compresión de datos	Representa los datos de forma aproximada usando menos componentes principales para almacenamiento o transmisión. La reconstrucción con los primeros k componentes minimiza el error cuadrático medio entre todas las aproximaciones lineales de rango k .
7. Preprocesamiento en aprendizaje automático	Mejora el desempeño y la eficiencia de los algoritmos al eliminar redundancia, reducir la dimensionalidad y concentrarse en las direcciones más informativas.
8. Detección de anomalías	Observaciones con gran error de reconstrucción al proyectarse sobre el subespacio generado por los componentes principales dominantes pueden considerarse atípicas o anómalas.
9. Análisis exploratorio de datos (EDA)	Ayuda a comprender las principales fuentes de variabilidad y la estructura de los datos a través de los valores propios, vectores propios y las cargas (cargas factoriales) de los componentes.
10. Modelado predictivo y regresión	Utiliza componentes principales como predictores para construir modelos más parsimoniosos, con menor riesgo de sobreajuste y mejor interpretabilidad.

Nota. PCA es una técnica lineal y no supervisada que transforma las variables originales $\mathbf{X} \in \mathbb{R}^{n \times p}$ en componentes no correlacionadas

$\mathbf{Z} = \mathbf{X}\mathbf{V}$, donde $\mathbf{V} = [\mathbf{v}_1 \ \mathbf{v}_2 \ \dots \ \mathbf{v}_p]$ es una matriz ortogonal de vectores propios de la matriz de covarianza $\mathbf{\Sigma} = \frac{1}{n-1} \mathbf{X}^T \mathbf{X}$.

Los valores propios $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$ indican la varianza explicada por cada componente principal. La varianza total es $\sum_{i=1}^p \lambda_i = \text{tr}(\mathbf{\Sigma})$.

REDUCCIÓN DE DIMENSIONALIDAD

Rachit Vargas (MBA | Engineer)

rachit.vargas@ulead.ac.cr

(+506) 8474-3543